

IA en local

Llibertat i sobirania



Jordi Mas (Softcatalà)

GitHub: [jordimas](#) · X: [@jordimash](#)

■ Tot seguit: aprofita la IA al teu ordinador

Una xerrada de **Martí SC**, enginyer de dades.

- Entendre com els models fan servir la memòria.
- Triar models adequats per al vostre ordinador.
- Ajustar-ne el rendiment i interpretar-ne la velocitat.

Hi aprofundirà amb explicacions tècniques i visualitzacions.

Us recomano que us hi quedeu!

La IA és una tecnologia transformadora

Està canviant com realitzem moltes tasques. Per exemple, els agents de programació han redefinit com desenvolupem programari.

El tancament com a avantatge competitiu

Molts laboratoris punters es reserven el coneixement perquè l'han convertit en un avantatge competitiu. Anècdota: irònicament, OpenAI rep el nom de ClosedAI.

Neguit creixent

Ara, per a moltes tasques habituals, depenem d'una tecnologia tancada, que s'executa al núvol i sobre la qual no tenim cap control.

Moment "Linux"

- Anys 2000: mancances de maquinari, aplicacions i usabilitat.
- Es dubtava que pogués ser una alternativa.
- Avui és una peça clau del món digital.

Què succeeix amb la IA local ara?

- Models i maquinari evolucionen ràpidament.
- **Encara no resol tots els casos d'ús per a tothom.**
- Cada cop permet fer més coses.

■ Què és una IA local?

IA local: el model s'executa al nostre ordinador o servidor, sense enviar les consultes a un servei extern.

- **Privacitat:** controlar on van les dades.
- **Autonomia:** poder treballar sense xarxa.
- **Continuïtat:** conservar les versions.
- **Control:** triar models i integracions.

Cal disposar del model i d'una eina que permeti executar-lo localment.

■ Què és una IA lliure?

No hi ha consens, però hi ha components clau:

- Dades d'entrenament obertes i avaluacions obertes.
- Codi i receptes d'entrenament accessibles.
- Pesos reutilitzables i codi d'inferència lliure.

Pesos oberts no vol dir necessàriament IA lliure.

En la meva opinió, perquè una IA sigui lliure, cal poder reproduir l'entrenament amb el maquinari adequat, a partir de dades, codi i metodologia publicats, seguint els principis de la **ciència oberta**.

■ Què podem fer amb la IA en local?

Temporalitat de les tasques:

En lot (p. ex., mentre som absents)

- Classificar documents i extreure'n informació.
- Extreure dades de factures i transcriure enregistraments.
- Revisar codi i generar proves.

Ús interactiu (cal bona latència i recursos al moment)

- Conversar amb un assistent: traducció, resums i preguntes.
- Transcriure en directe i conversar per veu.
- Programació amb agents.

■ Maquinari comú que es pot comprar a 2026

Equip	Preu aprox.	Gemma 3 12B
PC Intel / AMD · 32 GB	800–1.000 €	3–6 tok/s
PC RTX 5060 Ti 16 GB ¹	1.500–2.000 €	35–50 tok/s
MacBook Air M5 · 16 GB	1.300–1.500 €	12–16 tok/s

Tokens/s de generació estimats amb Gemma 3 12B a 4 bits, amb context curt i un usuari. Primera fila: només CPU. No són mesures pròpies; depenen de la configuració.

Preus orientatius d'equips nous a Catalunya (setembre de 2026). PC: només la torre. Mac: portàtil de 13". ¹ RAM: 32 GB.

Model i programari

- Proveu un model petit amb tasques reals en català.
- **Q4 K_M**: bon equilibri entre qualitat, memòria i velocitat.
- **MoE**: menys càlcul; memòria per a tots els pesos.

Maquinari

- Comproveu primer les eines al vostre equip.
- Reserveu memòria per als **pesos, el context i el sistema**.
- Ús interactiu: prioritzeu la GPU. En lot, podeu esperar.

■ Eines per executar-ho a casa

Eina	Per a qui
LM Studio	Descoberta fàcil de models, UI amable
Ollama	Terminal + UI, més control
AnythingLLM	Consultar els teus documents (RAG)

Totes tres funcionen a **macOS, Windows i Linux**.

Guia de Softcatalà: instal·lació i primer ús pas a pas.

softcatala.org/ia-local (<https://www.softcatala.org/ia-local/>)

Recomanacions per treballar en català, basades en les **avaluacions de models d'IA de Softcatalà** (<https://www.softcatala.org/ia-local/models-en-catala/llm/>).

Memòria de l'ordinador	Model recomanat	Alternativa
8 GB	Qwen3.5 9B · Q4	Gemma 3 4B · Q4
16 GB	Gemma 3 12B · Q4	Qwen3 14B · Q4
32 GB	Muse-Glimmer 30B · Q4	Qwen3.8 27B · Q4

Transcripció d'àudio:

- **whisper-large-v3-ca-3catparla** (Aina): més precisió.
- **whisper-large-v3-turbo** – més ràpid, qualitat similar.

Avís honest: els models Qwen (xinesos) poden evitar certs temes històrics i polítics. Pesos oberts no vol dir neutralitat.

■ Demostració: revisar codi en català

El meu equip: Ryzen AI Max+ PRO 395 · Radeon 8060S · 128 GB de RAM. Qwen CLI → llama.cpp local → Qwen3-Coder-Next Q4_K_M.

```
def mitjana(valors):  
    return sum(valors) / len(valors)
```

Encàrrec: detecta l'error, corregeix-lo i proposa tres proves. Respon en català. Si la llista és buida, cal retornar **None**.

```
bash demo-qwen.sh
```

■ Demostració: resultat comprovat

Qwen detecta un **ZeroDivisionError** quan la llista és buida.

```
def mitjana(valors):  
    if len(valors) == 0:  
        return None  
    return sum(valors) / len(valors)  
  
assert mitjana([1, 2, 3]) == 2.0  
assert mitjana([10, 20]) == 15.0  
assert mitjana([]) is None
```

3 proves superades en executar el codi amb Python.

■ Quant triga? Primera consulta i repetició

Maquinari: AMD Ryzen AI Max+ PRO 395 · Radeon 8060S · 128 GB RAM.
Model LLM: Qwen3-Coder-Next · 80B MoE (actius 3B) · Q4_K_M (~48,4 GB).
Execució: Qwen CLI → llama.cpp local amb acceleració GPU.

Mesura	Sense <i>cache</i>	Amb <i>cache</i>
Temps total	46,6 s	16,6 s
Prompt	38,2 s	9,6 s
Generació	7,0 s · 199 tokens	6,0 s · 172 tokens
Tokens reutilitzats	0	11.431

La generació es manté en uns 28–29 tokens/s: l'estalvi principal és processar menys context.

■ Comença aquesta setmana

1. **Comprova el teu equip** amb l'eina de compatibilitat.
2. **Instal·la** LM Studio o Ollama.
3. **Descarrega el model** que et toqui segons la RAM.
4. **Prova-ho:** redacció, resum o transcripció.

Tot el recorregut, pas a pas, a la guia de Softcatalà:

■ **softcatala.org/ia-local** (<https://www.softcatala.org/ia-local/>)

